머신러닝 분류 프로젝트 진행 가이드라인

0. 프로젝트 개요

항목	내용
목표	팀별로 선정한 데이터셋을 활용해 분류(Classification) 모델을 설계·구현·평가하고 결과를 발표
팀 구성	4~5팀, 팀당 3~5인 권장
산출물	① 코드(Jupyter Notebook / GitHub) ② 결과 보고서 ③ 발표자료(PPT)
핵심 역량	데이터 전처리, EDA, 모델링, 평가, 결과 해석 및 커뮤니케이션

---

1. 진행 일정

단계	산출물
주제/데이터 확정, 문제 정의, 초기 EDA	문제 정의서 1장
데이터 전처리, 피처 엔지니어링	전처리 코드
베이스라인 모델링 → 모델 비교 → 튜닝	모델 실험 로그
최종 모델 선정, 평가, 결과 해석	평가 결과표
보고서/발표자료 작성 및 리허설	최종 발표

일정은 팀/수업 상황에 맞게 조정하되, **단계를 건너뛰지 않는 것**이 중요합니다.

---

2. 단계별 세부 가이드

2-1. 문제 정의 (Problem Definition)

- 무엇을 예측하는가? (타겟 변수, 클래스 정의)
- 왜 이 문제가 중요한가? (비즈니스/사회적 맥락)
- 성공 기준은 무엇인가? (어떤 지표를 얼마나 개선하면 성공인가)

체크리스트

☐ 타겟 변수와 클래스(이진/다중) 명확히 정의했는가

☐ 데이터 출처와 라이선스를 확인했는가
☐ 클래스 불균형 여부를 사전에 파악했는가

2-2. 탐색적 데이터 분석 (EDA)

- 결측치, 이상치, 데이터 타입 확인
- 타겟 변수의 클래스 분포 확인 (불균형 여부 → 이후 평가지표/샘플링 전략에 직결)
- 주요 피처와 타겟 간의 관계 시각화 (히스토그램, 박스플롯, 상관관계 히트맵 등)
- 범주형 변수의 카디널리티(고유값 개수) 확인

체크리스트

☐ 결측치 비율과 처리 방향을 정리했는가
☐ 타겟 클래스 비율을 표/그래프로 제시했는가
☐ 피처 간 다중공선성(상관관계)을 확인했는가

2-3. 데이터 전처리 & 피처 엔지니어링

- 결측치 처리: 삭제 / 평균·중앙값 대체 / 모델 기반 대체
- 인코딩: 원-핫 인코딩(범주 적을 때) / 레이블 인코딩(순서 있는 경우) / 타겟 인코딩(카디널리티 높을 때)
- 스케일링: StandardScaler / MinMaxScaler (트리 계열 모델은 필수는 아니지만 로지스틱회귀·SVM·신경망은 필요)
- 클래스 불균형 대응: 언더샘플링 / 오버샘플링(SMOTE) / class_weight 조정 / 임계값(threshold) 조정
- 파생 변수 생성 시 근거를 함께 기록 (도메인 지식 기반 설명)

주의사항

- **Data Leakage 방지**: train/test 분리 이후에 스케일링·인코딩 fit을 수행 (test 데이터 정보가 학습에 새어 들어가지 않도록)
- 전처리 파이프라인은 `Pipeline` / `ColumnTransformer` 등으로 재현 가능하게 구성 권장

2-4. 모델링

1. **베이스라인 모델**부터 시작 (예: 로지스틱회귀, 결정트리) → 이후 성능 비교의 기준점 확보
2. **여러 모델 비교**: 로지스틱회귀 / 결정트리 / 랜덤포레스트 / 그래디언트부스팅(XGBoost, LightGBM) 등
3. **교차검증(Cross-Validation)** 으로 성능을 안정적으로 측정 (K-Fold, 불균형 데이터는 Stratified K-Fold 권장)
4. **하이퍼파라미터 튜닝**: GridSearchCV / RandomizedSearchCV / Optuna 등
5. 실험은 조건을 바꿔가며 **로그로 기록** (모델, 파라미터, 지표 결과를 표로 정리)

2-5. 모델 평가

- 단순 정확도(Accuracy)만으로 판단하지 말 것 — 특히 클래스 불균형 데이터셋에서는 왜곡될 수 있음
- 문제 성격에 맞는 지표를 함께 사용

상황	권장 지표
클래스 균형	Accuracy, F1-score
클래스 불균형 (사기/이탈/질병 등)	Precision, Recall, F1-score, ROC-AUC, PR-AUC
재현율이 중요한 경우 (놓치면 안 되는 케이스, 예: 사기·질병 탐지)	Recall, PR-AUC 우선 고려
정밀도가 중요한 경우 (오탐 비용이 큰 경우)	Precision 우선 고려

- Confusion Matrix로 오분류 패턴 확인
- 여러 모델의 지표를 표로 비교하고, 최종 모델 선정 근거를 명시

2-6. 결과 해석 (Interpretation)

- 피처 중요도(Feature Importance) 또는 SHAP 값으로 "왜" 이런 예측을 했는지 설명
- 비즈니스/도메인 관점에서 인사이트 도출 (예: "어떤 요인이 이탈에 가장 큰 영향을 미치는가")
- 모델의 한계와 개선 방향 언급 (데이터 한계, 추가로 필요한 피처 등)

2-7. 보고서 및 발표 준비

발표는 다음 구조를 권장합니다.

1. 문제 정의 및 데이터 소개 (1~2분)
2. EDA 핵심 인사이트 (2~3분)
3. 전처리 및 모델링 과정 (2~3분)
4. 평가 결과 및 최종 모델 선정 근거 (2~3분)
5. 결론 및 시사점, 한계 및 향후 개선 방향 (1~2분)

---

3. 공통 유의사항

- **재현성**: `random_state`(seed) 고정, 라이브러리 버전 명시
- **데이터 분할**: train/validation/test 분리 원칙 준수 (test는 최종 평가 전까지 보지 않기)
- **저작권/출처**: 사용한 데이터셋의 출처와 라이선스를 보고서에 명시
- **과적합 방지**: train/test 성능 격차를 반드시 확인하고 보고서에 기재
- **버전 관리**: GitHub 등으로 코드 이력 관리 권장 (팀 협업 효율 + 기여도 확인 가능)

---

4. 최종 제출 체크리스트

☐ 문제 정의 및 데이터 출처가 보고서 서두에 명시되어 있다
☐ EDA 핵심 결과가 시각화와 함께 제시되어 있다
☐ 전처리 과정과 근거가 설명되어 있다

☐ 최소 2개 이상의 모델을 비교했다
☐ 교차검증 결과가 포함되어 있다
☐ 문제 특성에 맞는 평가지표를 사용했다
☐ 결과에 대한 도메인 관점의 해석이 포함되어 있다
☐ 코드가 재현 가능한 형태(노트북/저장소)로 제공된다
☐ 발표자료가 위 흐름(문제정의→EDA→전처리→모델링→평가→결론)을 따른다